Définition de Spark

Définition de Spark
Généralité

- Framework de data processing pour le big data
  - Polyvalent : **API haut niveau** qui facilite les traitements sur hadoop
  - **Rapide** :
    - Calcul parallèle
    - Traitement **en mémoire** :
      - Plus rapide (que mapreduce)
      - Car évite les IO inutiles sur disques
    - Moteur d'**optimisation du DAG** (en map reduce, on optimise les 2 seules tâches map/reduce, alors que Spark optimise toute la chaîne)
  - Fault-tolerant
  - Codé en Scala

Définition de Spark
Généralité

- Les distributions de Spark :
  - HortonWorks
  - DataBricks
  - MapR
- Langages:
  - Scala
  - Python
  - R
  - …

Définition de Spark
Généralité

- Framework polyvalent
  - Manipulation et streaming de données structurées
  - Algo de machine learning distribué
  - Manipulation de graphes

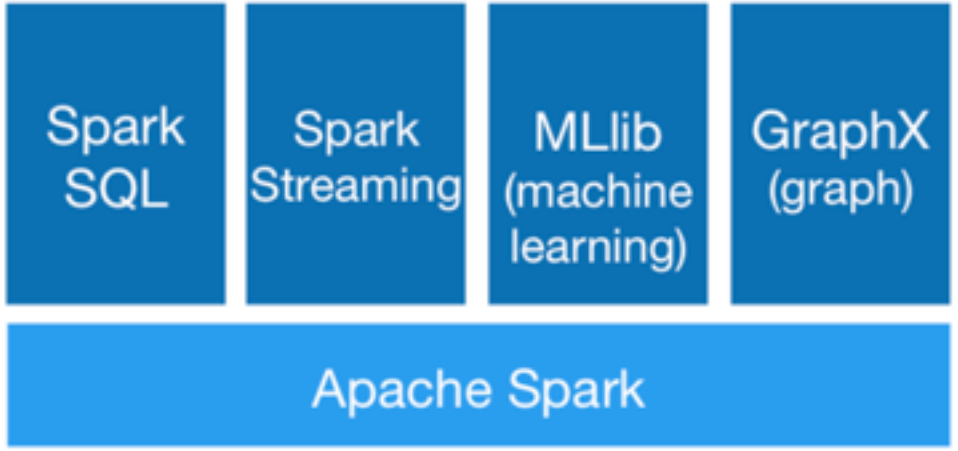

Définition de Spark
Module Spark SQL

- Principal outil pour manipuler la donnée structurée
- Accès unifié à plusieurs formats (csv, parquet, hive, …)

- Données structurées sous format « tabulaire »:
  - Dataframe
  - Dataset
- Manipulation type SQL

Définition de Spark
Module Spark Streaming

- Traitement de données en flux continue (micro-batch)
- Principales sources :
  - HDFS/S3
  - Kafka/Kinesis

- Applications
  - Streaming ETL / Enrichissement en temps réel
  - Détection en temps réel d’anomalie

Définition de Spark
Module MLLib

- Librairie de machine learning « scalable »
  - Algorithme de ML
  - Utilitaires :
    - Mathématique et statistique
    - Feature engineering
    - ML Pipelining
    - ...

Définition de Spark
Module GraphX

- Manipulation des graphes (basée sur RDD)

Manipulation de données avec Spark

Fonctionnement de Spark

Fonctionnement de Spark

- Formats de données
  - RDD (Resilient Distributed Datasets)
  - Dataframe
  - Dataset

Fonctionnement de Spark

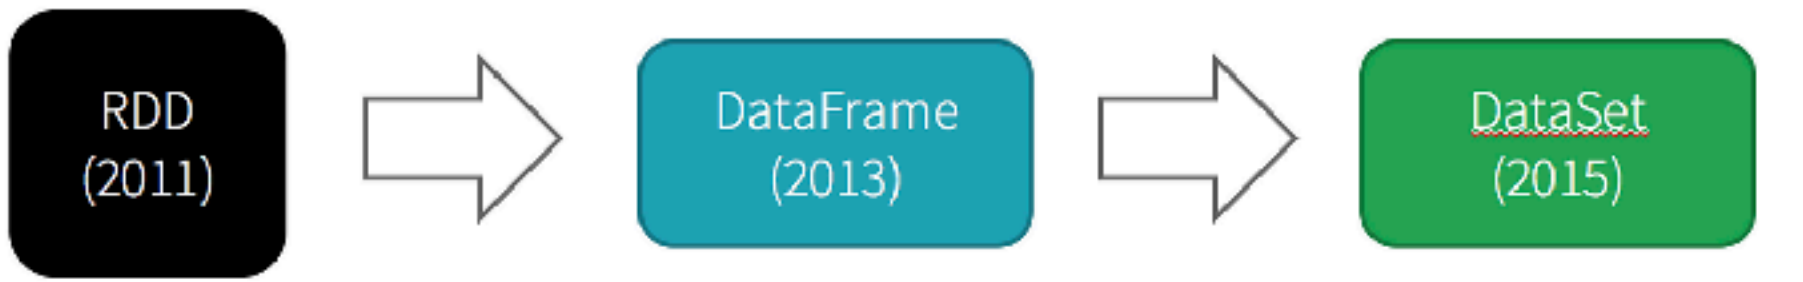

Distribute collection of JVM objects

Functional Operators (map, filter, etc.)

Distribute collection of Row objects

Expression-based operations and UDFs

Logical plans and optimizer

Fast/efficient internal representations

Internally rows, externally JVM objects

Almost the "Best of both worlds": type safe + fast

But slower than DF
Not as good for interactive analysis, especially Python

databricks

Fonctionnement de Spark
Format de données

- RDD

```
>>> rdd = sc.textFile('file:/root/cours-spark/dump/large-table/1913377.csv')
>>> header = rdd.first()
>>> rdd.map(lambda x:x.split(',')).take(5)
[[u'id', u'val1', u'val2'], [u'64727', u'3', u'195'], [u'64727', u'37', u'196'], [u'64727', u'93',
u'411'], [u'64727', u'97', u’185']]


>>> rdd\
... .filter(lambda row:row != header)\
... .map(lambda row:row.split(','))\
... .map(lambda row:(int(row[0]), int(row[1])))\
... .reduceByKey(lambda a, b: a + b)\
... .collect()
[(42880, 573), (23158, 459), (75291, 581), (64727, 550), (82087, 612)]
```

Fonctionnement de Spark
Format de données

- RDD
  - Resilient: recompute en cas d'échec
  - Distributed: partition et distribué sur plusieurs noeuds
  - Immutable: un RDD ne peut être modifié
  - Lazy: un RDD est une chaîne de calcul (transformation), mais n'exécute pas ces calculs (action)

Fonctionnement de Spark
Format de données

- RDD
  - Simple
  - Fault-tolerant
  - Définition du DAG par l'utilisateur
    - (-) Pas forcément optimisé

Fonctionnement de Spark
Format de données

- Dataframe

```
df.show()
# +-----+----+----+
# |   id|val1|val2|
# +-----+----+----+
# |64727|   3| 195|
# |64727|  37| 196|
# |64727|  93| 411|
# |64727|  97| 185|
# |64727|  84| 233|
# +-----+----+----+
# only showing top 5 rows

df.rdd.take(5)
[Row(id=64727, val1=3, val2=195), Row(id=64727, val1=37, val2=196), Row(id=64727, val1=93, val2=411), Row(id=64727,
val1=97, val2=185), Row(id=64727, val1=84, val2=233)]
```

Fonctionnement de Spark
Format de données

- Dataframe
  - Format structuré tabulaire
  - Lazy
  - Amélioration de la gestion mémoire (projet Tungsten)
  - Plan d’optimisation du DAG (Catalyst)
  - (-) Impossible d’avoir les erreurs avant de compiler… (compile-time type safety)

Utiliser Spark
RDD

- map
  - Convertir hh:mm:ss en hh

- flatMap :

- zip, union,

- pairRdd

Utiliser Spark
RDD

- filter :
  - Sélectionner les stations accessibles aux personnes à mobilité réduite (stop.txt, wheelchair_boarding=1.0)
  - sélectionner les gares de la B (stop.txt, stop_id finissant en 810:B)
- distinct : ID différents
- count :
  - Nombre de lignes
  - Nombre d’ID différents
  - Nombre de lignes pour un ID
- Stats

Utiliser Spark
RDD

- groupbBy :
  - Nombre de stations par zone_id (zone tarifaire)
  - Nombre de train par heure

- collect, first, take
- saveAsText

Monitoring: track the behavior of your applications
Tuning Guide: best practices to optimize performance and memory use
Job Scheduling: scheduling resources across and within Spark applications